

Compléments de Statistiques

Ce cours prend la suite de l'unité Tests Statistiques pour la Biologie du premier semestre. Le protocole en 7 points du déroulement d'un test est supposé acquis et ne sera pas redétaillé dans ce cours. Il sera détaillé pendant les TP d'informatique et il vous sera demandé lors des épreuves écrites.

TESTS déjà vus.

Les tests du chi-deux.

- * Comparaison des effectifs par classe à des effectifs théoriques : test du chi-deux d'adéquation ou de conformité.

Structure d'âge de la population française :

Classe d'âge	0-19	20-39	40-59	60-74	75-120
Pourcentage	24.6	28.1	26	13.6	7.7

Structure d'âge d'une population A :

Classe d'âge	0-19	20-39	40-59	60-74	75-120	Total
Effectifs	78	87	78	39	18	300

On compare les effectifs observés dans la population A aux effectifs théoriques attendus sous l'hypothèse que la répartition de la population A est semblable à celle de la population française.

Classe d'âge	0-19	20-39	40-59	60-74	75-120	Total
Effectifs théoriques attendus dans la population A	300 $\times 24.6$	300 $\times 28.1$	300 $\times 26$	300 $\times 13.6$	300 $\times 7.7$	300

- * Comparaison de la répartition des effectifs par classe de plusieurs populations = indépendance de la population d'origine et de la variable d'intérêt (dans l'exemple ci-dessous, la variable d'intérêt est la classe d'âge d'appartenance) : test du chi-deux d'homogénéité ou test du chi-deux d'indépendance.

Structure d'âge de 3 populations A, B, C :

Classe d'âge	0-19	20-39	40-59	60-74	75-120	Total
Effectifs pop A	78	87	78	39	18	300
Effectifs pop B	95	58	52	37	8	250
Effectifs pop C	73	82	75	36	18	284

Ce test s'énonce comme un test d'homogénéité de populations en ce qui concerne une variable d'intérêt, mais statistiquement nous avons appris à le traiter comme un test d'indépendance.

✱ Le vrai test d'indépendance de deux variables : test du chi-deux d'indépendance.

– Des plantes d'une même espèce ont des fleurs d'une certaine couleur (rouge, blanc, mauve) et un nombre de tiges (2,3,5,6,7,8,9). On peut se demander si le caractère « couleur des fleurs » est indépendant du caractère « nombre de tiges ».

– La couleur des yeux est-elle indépendante de la couleur des cheveux ?

✱ Le test binomial : un test qui peut se transformer en test du chi-deux.

– Test du chi-deux de conformité déguisé :

Phénotype	$[aa]$	$[AA]$	Total
Effectifs observés	17	63	80

Soit p la proportion de phénotype $[aa]$, on se demande si $p = 0,25$ ou pas. On compare les effectifs observés pour $[aa]$ aux effectifs théoriques attendus sous l'hypothèse que $p = 0,25$.

Phénotype	$[aa]$	$[AA]$	Total
Effectifs théoriques attendus	20	60	80

– Test du chi-deux d'indépendance déguisé :

	Fumeur	Non fumeur	Total
Homme	84	216	300
Femme	60	200	260

Soit p_H et p_F les proportions respectives d'hommes et de femmes fumeurs/ses. Se demander si $p_H = p_F$ revient à se demander si la population d'origine (homme ou femme) est indépendante de la variable "fumer ou ne pas fumer", ou bien revient à se demander si les deux populations (les hommes et les femmes) sont homogènes en ce qui concerne l'usage du tabac.

– Une petite différence toutefois : les tests du chi-deux sont forcément bilatéraux alors que les tests binomiaux peuvent être unilatéraux. Si à la sortie d'un test du chi-deux on a rejeté H_0 et décidé H_1 , il faudra revenir aux données pour savoir

de quel côté on aurait rejeté en utilisant un test binomial.

– Une autre petite différence : les tests du chi-deux imposent que les effectifs théoriques soient supérieurs ou égaux à 5 alors que les tests binomiaux n'imposent rien.

Les tests gaussiens d'adéquation de la moyenne théorique à une valeur théorique m_0 .

On dispose de n variables indépendantes notées $X_1, \dots, X_n$ de même loi qu'une variable générique notée X , et l'on a de bonnes raisons de penser que cette variable X suit une loi gaussienne de moyenne théorique m et de variance σ^2 . Cette hypothèse signifie que l'on pense que la loi de X est une loi continue (des longueurs, des temps, des poids and so on) qui se répartit symétriquement autour d'une valeur moyenne théorique m . La dispersion autour de cette valeur moyenne théorique est évaluée par l'écart-type σ .

Exemple : En France, la taille moyenne théorique à 10 ans d'un chêne pédonculé est 5 mètres. La taille à 10 ans d'un chêne pédonculé choisi au hasard en France peut être considéré comme une variable aléatoire gaussienne : selon les conditions climatiques, la nature du sol et beaucoup d'autres facteurs, la taille exacte d'un individu de 10 ans ne sera pas 5 mètres, mais sera répartie symétriquement autour de 5 mètres.

Notre problématique est la suivante : on a des raisons de penser que dans une région française donnée, la taille moyenne théorique à 10 ans de l'un de ces chênes est nettement supérieure à 5 mètres et on voudrait le vérifier statistiquement. On note X la variable générique « taille à 10 ans d'un chêne pédonculé de cette région », cette variable suit donc une loi gaussienne de moyenne théorique m dont on subodore qu'elle pourrait être strictement supérieure à 5 mètres, et on relève les hauteurs de 43 chênes pédonculés de 10 ans d'âge de cette région. On obtient un échantillon $X_1, \dots, X_{43}$ de loi gaussienne de moyenne théorique m et de variance σ^2 . La question posée mathématiquement est $H_0 : m = 5$ ou bien $H_1 : m > 5$?

Statistiques utilisées :

* Si σ est connu (ce qui n'est généralement pas le cas) on utilise la statistique

$$U_0 = \frac{\sqrt{43}(\bar{X} - 5)}{\sqrt{\sigma^2}}$$

La statistique U_0 suit la loi $\mathcal{N}(0,1)$ sous H_0 et est donc centrée en 0 sous H_0 . Elle se décale à droite de 0 si $m > 5$ (elle se décale à gauche de 0 si $m < 5$ mais la question posée n'est pas celle-ci). Lorsque l'on teste $H_0 : m = 5$ contre $H_1 : m > 5$ on décidera H_1

- soit si $U_0^{obs} > seuil$, la valeur *seuil* étant fonction du risque d'erreur α que l'on s'autorise,
- soit si la probabilité qu'une loi normale $\mathcal{N}(0,1)$ dépasse U_0^{obs} est inférieure au risque d'erreur α que l'on ne veut pas dépasser.

* Si σ est inconnu (ce qui est généralement le cas) on utilise la statistique

$$T_0 = \frac{\sqrt{43}(\bar{X} - 5)}{\sqrt{S^2}}$$

avec

$$S^2 = \frac{1}{42} \sum_{i=1}^{43} (X_i - \bar{X})^2.$$

La statistique T_0 suit la loi $\mathcal{T}(42)$ sous H_0 et est donc centrée en 0 sous H_0 . Elle se décale à droite de 0 si $m > 5$ (elle se décale à gauche de 0 si $m < 5$ mais la question posée n'est pas celle-ci). Le raisonnement est le même qu'avec la statistique U_0 .

COMPLÉMENT I : populations gaussiennes appariées.

Ce cas est un cas particulier des tests gaussiens d'adéquation de la moyenne théorique à une valeur théorique.

Un individu générique donne 2 réponses, chacune des réponses étant une variable gaussienne.

Par exemple, un individu est une parcelle que l'on sépare en deux moitiés, la première moitié sera semée avec une variété A et la seconde moitié sera semée avec une variété B. La variable générique de réponse sera (X,Y) avec :

X = rendement de la variété A (en kilos / hectare) de la parcelle,

Y = rendement de la variété B (en kilos / hectare) de la parcelle.

On peut supposer que X et Y sont deux variables aléatoires gaussiennes :

m_A est le rendement moyen théorique de la variété A

m_B est le rendement moyen théorique de la variété B,

σ_A évalue la dispersion de rendement pour la variété A,

σ_B évalue la dispersion de rendement pour la variété B.

La problématique naturelle est est-ce que les deux variétés ont le même rendement moyen théorique, la question mathématique associée est : $H_0 : m_A = m_B$ ou bien $H_1 :$

$m_A \neq m_B$?

Remarque : si on avait suspecté à priori que la variété A avait un meilleur rendement moyen théorique, la question mathématique associée aurait été : $H_0 : m_A = m_B$ ou bien $H_1 : m_A > m_B$?

Nous allons **apparier** X et Y en posant

$$Z = X - Y.$$

Cette nouvelle variable est égale à la différence de rendement entre la variété A et la variété B .

On « interroge » alors 20 parcelles et on obtient en réponse 20 couples

$$(X_1, Y_1), \dots, (X_{20}, Y_{20})$$

que l'on **apparie** en posant

$$Z_i = X_i - Y_i$$

afin d'obtenir un échantillon $Z_1, \dots, Z_{20}$ de la variable générique $Z = X - Y$.

La loi de Z peut être supposée gaussienne, d'espérance m et de variance σ^2 . Par propriété de l'espérance on a :

$$m = m_A - m_B$$

mais ATTENTION (sauf dans des cas très particuliers) :

$$\sigma^2 \neq \sigma_A^2 + \sigma_B^2.$$

En effet, une condition pour que $\mathbb{V}(X - Y) = \mathbb{V}(X) + \mathbb{V}(Y)$ est que X et Y soient indépendantes (la condition la plus faible pour avoir cette égalité est que X et Y soient non corrélées) et on peut penser que X et Y ne le sont pas. Ou tout du moins on ne peut pas l'affirmer à priori.

Le problème est donc ramené au test de $H_0 : m = 0$ contre $H_1 : m \neq 0$ à partir d'un 20-échantillon dont la variance σ^2 est inconnue.

Remarque : si on avait suspecté à priori que la variété A avait un meilleur rendement, la question mathématique associée aurait été : $H_0 : m = 0$ contre $H_1 : m > 0$ et si on avait suspecté à priori que la variété B avait un meilleur rendement, la question mathématique associée aurait été : $H_0 : m = 0$ contre $H_1 : m < 0$.

La statistique utilisée est :

$$T_0 = \frac{\sqrt{20}(\bar{Z} - 0)}{\sqrt{S^2}} = \frac{\sqrt{20} \bar{Z}}{\sqrt{S^2}}$$

avec

$$\bar{Z} = \frac{1}{20} \sum_{i=1}^{20} Z_i = \bar{X} - \bar{Y}$$

et

$$S^2 = \frac{1}{19} \sum_{i=1}^{20} (Z_i - \bar{Z})^2.$$

La statistique T_0 suit la loi $\mathcal{T}(19)$ sous H_0 et est donc centrée en 0 sous H_0 et se décale à droite de 0 si $m > 0$ et à gauche de 0 si $m < 0$. Lorsque l'on teste $H_0 : m = 0$ contre $H_1 : m \neq 0$ on décidera H_1

– soit si $|T_0^{obs}| > seuil$, la valeur *seuil* étant fonction du risque d'erreur α que l'on s'autorise,

– soit si la probabilité que la valeur absolue d'une loi de Student $|\mathcal{T}(19)|$ dépasse $|T_0^{obs}|$ est inférieure au risque d'erreur α que l'on ne veut pas dépasser.

Ce test est donc une version simple du test gaussien d'adéquation de la moyenne théorique à une valeur théorique, puisqu'il est toujours à variance inconnue et que l'on teste toujours l'adéquation de la moyenne théorique (de la différence) à la valeur théorique 0.

COMPLÉMENT II : théorème central limite ou comment traiter les échantillons non gaussiens.

Toutes les variables ne sont pas gaussiennes, par exemple les variables de Bernoulli (prenant les valeurs 0 ou 1) sont très loin d'être des variables gaussiennes mais d'autres variables continues peuvent ne pas être gaussienne. Citons les temps de panne, temps de survie, temps de guérison qui sont en général non gaussiennes. Pour les variables de Bernoulli, $X_i = 1$ avec probabilité p et $X_i = 0$ avec probabilité $1 - p$, on a vu que leur somme $S_n = \sum_{i=1}^n X_i$ était une variable binomiale qui s'approxime bien et assez rapidement par une loi gaussienne :

Théorème (approximation normale de la loi binomiale) : Soit S_n une variable de loi binomiale de paramètres n et p , $0 < p < 1$.

$$\frac{S_n - np}{\sqrt{np(1-p)}} \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} Z \sim \mathcal{N}(0,1).$$

Autrement dit, pour tout réel t , lorsque n est suffisamment grand, on a :

$$P\left(\frac{S_n - np}{\sqrt{np(1-p)}} \leq t\right) \approx P(Z \leq t) \text{ où } Z \sim \mathcal{N}(0,1)$$

En pratique, ce résultat fonctionne dès que $n \geq 50$, $np \geq 15$ et $n(1-p) \geq 15$.

La notation $Z_n \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} Z$ se lit : Z_n converge en loi vers Z quand n tend vers $+\infty$.

En prenant la notation habituelle :

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

remarquons que

$$\frac{S_n - np}{\sqrt{np(1-p)}} = \frac{\sqrt{n}(\bar{X} - p)}{\sqrt{p(1-p)}}.$$

Or p est l'espérance de X_i et $p(1-p)$ est la variance de X_i . On a donc

$$\frac{S_n - np}{\sqrt{np(1-p)}} = \frac{\sqrt{n}(\bar{X} - \mathbb{E}(X_i))}{\sqrt{\mathbb{V}(X_i)}}.$$

Le théorème central limite (TCL ou TLC en abrégé) généralise ce résultat à toutes les variables aléatoires. Ce résultat très puissant explique l'importance qu'ont les lois gaussiennes dans le domaine des statistiques.

Théorème (TCL ou TLC, théorème central limite ou de la limite centrale) : soit un n -échantillon $X_1, \dots, X_n$ d'une variable générique admettant une espérance m et une variance σ^2 .

$$\frac{\sqrt{n}(\bar{X} - m)}{\sqrt{\sigma^2}} \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} Z \sim \mathcal{N}(0,1).$$

Autrement dit, pour tout réel t , lorsque n est suffisamment grand, on a :

$$P\left(\frac{\sqrt{n}(\bar{X} - m)}{\sqrt{\sigma^2}} \leq t\right) \approx P(Z \leq t) \text{ où } Z \sim \mathcal{N}(0,1)$$

En général, la variance σ^2 de l'échantillon est inconnue. On a vu dans le cas des échantillons gaussiens, qu'en remplaçant σ^2 par son estimateur

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

on passait de

$$U = \frac{\sqrt{n}(\bar{X} - m)}{\sqrt{\sigma^2}} \sim \mathcal{N}(0,1)$$

à

$$T = \frac{\sqrt{n}(\bar{X} - m)}{\sqrt{S^2}} \sim \mathcal{T}(n-1).$$

La loi de Student est une particularité des échantillons gaussiens, dans le cas des grands échantillons traité par le TLC, la loi de Student n'intervient plus. La version du TLC à variance inconnue s'énonce comme suit :

Théorème (TCL ou TLC, variante à variance inconnue) : soit un n -échantillon $X_1, \dots, X_n$ d'une variable générique admettant une espérance m et une variance σ^2 inconnue et estimée par S^2 .

$$\frac{\sqrt{n}(\bar{X} - m)}{\sqrt{S^2}} \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} Z \sim \mathcal{N}(0,1).$$

Autrement dit, pour tout réel t , lorsque n est suffisamment grand, on a :

$$P\left(\frac{\sqrt{n}(\bar{X} - m)}{\sqrt{S^2}} \leq t\right) \approx P(Z \leq t) \text{ où } Z \sim \mathcal{N}(0,1)$$

Remarque : il n'y a pas de contradiction avec les grands échantillons gaussiens car la loi de Student $\mathcal{T}(n-1)$ elle-même s'approxime rapidement par la loi $\mathcal{N}(0,1)$ lorsque n devient grand.

A partir de ces théorèmes, il devient possible de réaliser les tests d'adéquation de la moyenne théorique m à une valeur théorique m_0 même si l'échantillon de départ n'est pas gaussien. Il faut seulement qu'il soit de taille suffisamment grande. La statistique utilisée pour tester $H_0 : m = m_0$ est

$$U_0 = \frac{\sqrt{n}(\bar{X} - m_0)}{\sqrt{S^2}}$$

comme dans le cas gaussien. Cette statistique suit approximativement la loi $\mathcal{N}(0,1)$ sous H_0 et est donc centrée en 0 sous H_0 . Elle se décale à droite de 0 si $m > m_0$ et

elle se décale à gauche de 0 si $m < m_0$. Le protocole du test reste le même.

COMPLÉMENT III : Le test d'homogénéité des moyennes de 2 échantillons gaussiens indépendants.

Dans le cadre des tests gaussiens, pour le moment nous nous sommes interrogés sur

- l'adéquation de la moyenne théorique d'un unique échantillon à une valeur théorique m_0 ,
- l'égalité des moyennes théoriques de deux échantillons appariés.

Il reste à s'interroger sur l'égalité des moyennes de deux échantillons non appariés, on exigera alors que les deux échantillons soient indépendants.

Remarque : la suite de ce cours consisterait à s'interroger sur l'égalité des moyennes théoriques de d échantillons indépendants, cette généralisation s'appelle Analyse de la Variance ou ANOVA et n'est pas dans le programme de ce cours.

Supposons que l'on ait semé des n_A parcelles avec une variété A et que l'on ait semé n_B parcelles avec une variété B , on a au total $N = n_A + n_B$ et on suppose que ces N parcelles sont indépendantes.

On note :

X = rendement d'une parcelle semée avec la variété A (en kilos / hectare),
on observe les rendements $X_1, \dots, X_{n_A}$ de n_A parcelles semées avec la variété A .

Y = rendement d'une parcelle semée avec la variété B (en kilos / hectare),
on observe les rendements $Y_1, \dots, Y_{n_B}$ de n_B parcelles semées avec la variété B .

On peut supposer que les variables génériques X et Y sont deux variables aléatoires gaussiennes :

m_A est le rendement moyen théorique de la variété A
 m_B est le rendement moyen théorique de la variété B ,
 σ_A évalue la dispersion de rendement pour la variété A ,
 σ_B évalue la dispersion de rendement pour la variété B .

Comme dans le paragraphe Complément I, la problématique naturelle est est-ce que les deux variétés ont le même rendement moyen théorique, la question mathématique associée est : $H_0 : m_A = m_B$ ou bien $H_1 : m_A \neq m_B$?

Remarque : comme dans le paragraphe Complément I, si on avait suspecté à priori que la variété A avait un meilleur rendement moyen théorique, la question mathématique associée aurait été : $H_0 : m_A = m_B$ ou bien $H_1 : m_A > m_B$?

Remarque sur l'appariement et l'indépendance : en pratique, si $n_A = n_B$, il n'est pas toujours facile de trancher entre l'appariement et l'indépendance de X et de Y . L'indépendance signifie que l'observation x de X ne donne aucune information sur la valeur y que va prendre Y . Par exemple, si on sait que l'observation x est plus grande que la moyenne théorique m_A , on ne peut ni dire que la valeur observée y sera plus grande, ni plus petite, ni très proche de la moyenne théorique m_B . Par ailleurs, l'appariement de couples demande à ce que le couple provienne d'un même individu. Si $n_A = n_B$ et que les $n_A + n_B$ parcelles sont à la fois très proches voire identiques en termes de condition de culture et pourtant statistiquement indépendantes, on peut à la fois les appairer et les traiter comme deux échantillons indépendants. Si on a le choix et un logiciel sous la main, on réalisera les deux tests.

Dans ce paragraphe, nous supposons que les deux échantillons sont indépendants, et plus précisément dans notre exemple, que toutes les parcelles sont indépendantes.

Notations :

$$\text{Variété } A : \quad \bar{X} = \frac{1}{n_A} \sum_{i=1}^{n_A} X_i \quad \text{et} \quad S_X^2 = \frac{1}{n_A - 1} \sum_{i=1}^{n_A} (X_i - \bar{X})^2.$$

$$\text{Variété } B : \quad \bar{Y} = \frac{1}{n_B} \sum_{i=1}^{n_B} Y_i \quad \text{et} \quad S_Y^2 = \frac{1}{n_B - 1} \sum_{i=1}^{n_B} (Y_i - \bar{Y})^2.$$

Hypothèse supplémentaire :

$$\sigma_A^2 = \sigma_B^2 = \sigma^2$$

(les variances des deux échantillons sont égales).

Théorème : Sous l'hypothèse $\sigma_A^2 = \sigma_B^2 = \sigma^2$, la statistique utilisée pour tester $H_0 : m_A = m_B$ contre $H_1 : m_A \neq m_B$, ou contre $H'_1 : m_A > m_B$, ou contre $H''_1 : m_A < m_B$ est

$$T_0 = \frac{(\bar{X} - \bar{Y})}{\sqrt{\mathcal{S}^2} \sqrt{\frac{1}{n_A} + \frac{1}{n_B}}} \quad \text{avec} \quad \mathcal{S}^2 = \frac{(n_A - 1) S_X^2 + (n_B - 1) S_Y^2}{n_A + n_B - 2}.$$

La statistique T_0 suit la loi de Student $\mathcal{T}(n_A + n_B - 2)$ sous H_0 , elle est donc centrée en 0 sous H_0 et elle se décale à droite de 0 si $m_A > m_B$ et à gauche de 0 si $m_A < m_B$.

A partir de ce théorème, le protocole habituel des tests en 7 points s'applique.

Remarque : la variable aléatoire $\mathcal{S}^2$ est un estimateur de σ^2 variance commune aux deux échantillons. Elle est une moyenne pondérée des estimateurs S_X^2 et S_Y^2 qui sont tous deux des estimateurs de σ^2 (puisque $\sigma_A^2 = \sigma_B^2 = \sigma^2$). L'intuition nous conduirait à prendre comme estimateur de σ^2 la variable

$$\frac{n_A}{n_A + n_B} S_X^2 + \frac{n_B}{n_A + n_B} S_Y^2,$$

mais pour des raisons hors programme on doit prendre

$$\mathcal{S}^2 = \frac{n_A - 1}{n_A + n_B - 2} S_X^2 + \frac{n_B - 1}{n_A + n_B - 2} S_Y^2.$$

Et si ... les variances ne sont pas égales, ou si les échantillons ne sont pas gaussiens mais de grande taille ? Dans le premier cas, il existe un test asymptotique (si n_A et n_B sont grands) proposé par le logiciel, et dans le second cas une variante du TLC s'applique et l'on peut considérer que lorsque n_A et n_B sont suffisamment grands, la loi de T_0 sous H_0 est approximée par la loi $\mathcal{N}(0,1)$.

Et si ... les deux échantillons sont de même taille et qu'ils sont indépendants ? On a alors le choix entre appairier les échantillons et ne pas les appairier. Si l'on dispose d'un logiciel, le plus judicieux est de lancer les deux tests qui doivent aboutir à la même conclusion. Si ce n'est pas le cas, il faut réfléchir à ce que cela signifie sur notre choix d'appariement. Lorsque le choix d'appariement consiste à appairier des parcelles le plus proches possibles en termes de conditions de culture, le test sur données appariées est meilleur (plus puissant) que le test sur données non appariées.

Notons bien que si les échantillons sont indépendants mais pas de même taille ou qu'ils sont de même taille mais ne sont pas indépendants, on n'a pas le choix sur le test à réaliser.

Intervalles de confiance

Définition : Soit θ un paramètre réel. On dit qu'un intervalle aléatoire (c'est à dire un intervalle dont les bornes sont des variables aléatoires) I est un intervalle de confiance pour θ de niveau de confiance $1 - \alpha$ avec $\alpha \in]0,1[$ si :

– L'intervalle observé, noté I_{obs} , est calculable à partir des observations dont on dispose ;

$$- P(\theta \in I) \geq 1 - \alpha.$$

Si $P(\theta \in I) = 1 - \alpha$, l'intervalle de confiance est dit « exact ».

Remarque : les valeurs usuelles de α sont 10%, 5%, 1%.

Comment construire un intervalle de confiance ?

- * Choisir un estimateur $\hat{\theta}_n$ de θ ;
- * Transformer $\hat{\theta}_n$ en une variable aléatoire dont la loi est libre (une loi est libre lorsqu'elle ne dépend ni des observations ni des paramètres, ici le paramètre est θ) et dans laquelle θ est le seul terme inconnu/non calculable et apparaît comme un terme pouvant être isolé des autres termes (cf exemples) ;
- * Déterminer les quantiles de la loi libre ;
- * Effectuer un calcul « pivotale » de manière à obtenir un intervalle de confiance pour θ .

Exemple : intervalle de confiance pour l'espérance d'une loi normale lorsque la variance est connue.

Le bruit en décibels au décollage d'un avion entendu dans une commune avoisinant un aéroport peut être modélisé par une variable aléatoire de loi normale $\mathcal{N}(m, \sigma^2)$. On suppose que $\sigma^2 = 49$. Donner un intervalle de confiance pour m au niveau de confiance $1 - \alpha$.

Application numérique : dans cette commune, on a relevé les décibels au décollage de 900 avions. La moyenne empirique des bruits en décibels au décollage de ces 900 avions a été observée à 50 décibels. Donner un intervalle de confiance au niveau de confiance 95% pour le nombre moyen de décibels entendu dans cette commune au décollage d'un avion.

Réponse :

✱ Je choisis un estimateur de m . Je choisis la moyenne empirique (what else?)

$$\overline{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

La loi de $\overline{X}_n$ est la loi $\mathcal{N}(m, \frac{\sigma^2}{n})$.

✱ Je cherche une transformation de $\overline{X}_n$ en une variable dont la loi ne dépende ni de m ni des observations. Pour cela, dans ce cas, je centre et je réduis $\overline{X}_n$:

$$U_n := \frac{\sqrt{n}(\overline{X}_n - m)}{\sqrt{49}} \sim \mathcal{N}(0, 1).$$

✱ Je cherche les quantiles u_1 et u_2 de la loi $\mathcal{N}(0, 1)$ pour que la probabilité que U_n tombe entre u_1 et u_2 soit égale à $1 - \alpha$, c'est à dire je cherche u_1 et u_2 tels que

$$P(u_1 \leq U_n \leq u_2) = 1 - \alpha.$$

On remarque qu'il y a deux inconnues u_1 et u_2 et une seule équation. Pour ne pas déséquilibrer l'intervalle, pour ne pas favoriser un côté par rapport à l'autre, on prend :

$$\begin{cases} P(U_n \leq u_1) = \frac{\alpha}{2} \\ P(U_n \geq u_2) = \frac{\alpha}{2} \end{cases}$$

Pour illustrer, prenons $\alpha = 5\%$, on cherche u_1 et u_2 tels que

$$P(u_1 \leq U_n \leq u_2) = 0,95,$$

ce qui revient à chercher u_1 et u_2 tels que

$$\begin{cases} P(U_n \leq u_1) = 0,025 \\ P(U_n \geq u_2) = 0,025 \end{cases}$$

ou encore, en se ramenant à la fonction de répartition, ce qui revient à chercher u_1 et u_2 tels que

$$\begin{cases} F_{\mathcal{N}(0, 1)}(u_1) = 0,025 \\ F_{\mathcal{N}(0, 1)}(u_2) = 0,975. \end{cases}$$

On trouve $u_1 = -1,96$ et $u_2 = 1,96$.

Remarque : les deux quantiles sont opposés l'un à l'autre car la loi $\mathcal{N}(0, 1)$ est symétrique. C'est également le cas de la loi de Student mais ce n'est pas le cas de la loi du chi-deux.

* On a :

$$P(u_1 \leq \frac{\sqrt{n}(\bar{X}_n - m)}{\sqrt{49}} \leq u_2) = 1 - \alpha.$$

Or

$$\begin{aligned} u_1 &\leq \frac{\sqrt{n}(\bar{X}_n - m)}{\sqrt{49}} \leq u_2 \\ \Leftrightarrow \frac{u_1\sqrt{49}}{\sqrt{n}} &\leq \bar{X}_n - m \leq \frac{u_2\sqrt{49}}{\sqrt{n}} \\ \Leftrightarrow -\bar{X}_n + \frac{u_1\sqrt{49}}{\sqrt{n}} &\leq -m \leq -\bar{X}_n + \frac{u_2\sqrt{49}}{\sqrt{n}} \end{aligned}$$

et en multipliant par -1 on change le sens des inégalités :

$$\Leftrightarrow \bar{X}_n - \frac{u_2\sqrt{49}}{\sqrt{n}} \leq m \leq \bar{X}_n - \frac{u_1\sqrt{49}}{\sqrt{n}},$$

puisque $u_1 = -u_2$ on a :

$$\Leftrightarrow \bar{X}_n - \frac{u_2\sqrt{49}}{\sqrt{n}} \leq m \leq \bar{X}_n + \frac{u_2\sqrt{49}}{\sqrt{n}}.$$

Autrement dit :

$$P(\bar{X}_n - \frac{u_2\sqrt{49}}{\sqrt{n}} \leq m \leq \bar{X}_n + \frac{u_2\sqrt{49}}{\sqrt{n}}) = 1 - \alpha.$$

L'intervalle

$$I = \left[\bar{X}_n - \frac{u_2\sqrt{49}}{\sqrt{n}} ; \bar{X}_n + \frac{u_2\sqrt{49}}{\sqrt{n}} \right]$$

est un intervalle de confiance pour m au niveau de confiance $1 - \alpha$.

Application numérique : $n = 900$; $\alpha = 5\%$; $u_2 = 1,96$; $\bar{X}_n^{obs} = 50$. On obtient comme intervalle de confiance pour m observé :

$$I^{obs} = \left[50 - \frac{1,96 \times 7}{30} ; 50 + \frac{1,96 \times 7}{30} \right] = [49,54 ; 50,46].$$

Quels sont les autres cas ?

- ※ Intervalle de confiance pour l'espérance d'une loi normale lorsque la variance est inconnue.

Si dans l'exemple précédent la variance n'avait pas été connue et égale à 49 mais inconnue et estimée par

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i)^2 - \frac{n}{n-1} (\bar{X}_n)^2$$

la transformation de $\bar{X}_n$ en une variable de loi libre aurait été

$$T_n := \frac{\sqrt{n}(\bar{X}_n - m)}{\sqrt{S_n^2}} \sim \mathcal{T}(n-1)$$

et les quantiles t_1, t_2 auraient été ceux de la loi de Student à $n-1$ degrés de liberté :

$$P(t_1 \leq T_n \leq t_2) = 1 - \alpha.$$

Pour illustrer, avec $\alpha = 5\%$ et $n = 900$, on trouve $t_2 = 1,962$ (la loi de Student à 899 degrés de liberté est pratiquement une loi normale centrée réduite) et le même calcul pivotale nous donne comme intervalle de confiance pour m au niveau de confiance $1 - \alpha$:

$$I = \left[\bar{X}_n - \frac{t_2 \sqrt{S_n^2}}{\sqrt{n}} ; \bar{X}_n + \frac{t_2 \sqrt{S_n^2}}{\sqrt{n}} \right].$$

Cet intervalle est notamment l'intervalle pour la différence des moyennes théoriques dans le cas de données appariées.

- ※ Intervalle de confiance pour la variance d'une loi normale lorsque son espérance est inconnue.

Cette fois on choisit

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = \left(\frac{1}{n-1} \sum_{i=1}^n X_i^2 \right) - \frac{n}{n-1} (\bar{X}_n)^2$$

comme estimateur de la variance σ^2 et la transformation de S_n^2 en une variable de loi libre est

$$Z_n := \frac{(n-1)S_n^2}{\sigma^2} \sim \chi^2(n-1)$$

(loi du chi-deux à $n - 1$ degrés de liberté). Les quantiles z_1, z_2 sont ceux de la loi de la loi du chi-deux à $n - 1$ degrés de liberté

$$P(z_1 \leq Z_n \leq z_2) = 1 - \alpha$$

et cette fois ils ne sont pas opposés l'un à l'autre car la loi du chi-deux n'est pas symétrique. On doit résoudre pour les trouver les deux équations ci-dessous :

$$\begin{cases} P(Z_n \leq z_1) = \frac{\alpha}{2} \\ P(Z_n \geq z_2) = \frac{\alpha}{2} \end{cases}$$

ou encore, en se ramenant à la fonction de répartition de la loi $\chi^2(n - 1)$:

$$\begin{cases} F_{\chi^2(n-1)}(z_1) = \frac{\alpha}{2} \\ F_{\chi^2(n-1)}(z_2) = 1 - \frac{\alpha}{2}. \end{cases}$$

L'intervalle de confiance pour σ^2 au niveau de confiance $1 - \alpha$ est :

$$I = \left[\frac{(n-1)S_n^2}{z_2} ; \frac{(n-1)S_n^2}{z_1} \right].$$

Notons que puisque nous connaissons maintenant la loi la statistique Z_n , nous serions aussi capables de construire un test statistique de l'hypothèse $H_0 : \sigma = \sigma_0$ contre ses alternatives en utilisant la statistique

$$Z_0 := \frac{(n-1)S_n^2}{\sigma_0^2}.$$

✱ Variante du précédent : intervalle de confiance pour la variance d'une loi normale lorsque son espérance m est connue.

Cette fois on choisit

$$V_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - m)^2 = \left(\frac{1}{n-1} \sum_{i=1}^n X_i^2 \right) - m^2$$

comme estimateur de la variance σ^2 et la transformation de V_n^2 en une variable de loi libre est

$$Z'_n := \frac{n V_n^2}{\sigma^2} \sim \chi^2(n)$$

(loi du chi-deux à n degrés de liberté).

La suite de la démarche est identique à celle du paragraphe précédent.

✱ **Intervalle de confiance pour la différence des espérances de deux lois normales indépendantes de variances inconnues mais égales.**

Les notations sont celles du chapitre I. La taille du premier échantillon est notée n_A et la taille du second échantillon est notée n_B . La moyenne théorique (ou espérance) du premier échantillon est notée m_A et la moyenne théorique (ou espérance) du second échantillon est notée m_B . Dans ce cas, on choisit $\bar{X}_{n_A} - \bar{Y}_{n_B}$ comme estimateur de la différence des moyennes théoriques $m_A - m_B$, et la variable de loi libre associée est

$$T_H := \frac{(\bar{X}_{n_A} - \bar{Y}_{n_B}) - (m_A - m_B)}{\sqrt{\mathcal{S}^2} \sqrt{\frac{1}{n_A} + \frac{1}{n_B}}} \quad \text{avec} \quad \mathcal{S}^2 = \frac{(n_A - 1) S_X^2 + (n_B - 1) S_Y^2}{n_A + n_B - 2}.$$

La variable T_H suit la loi de Student à $n_A + n_B - 2$ degrés de liberté :

$$T_H \sim \mathcal{T}(n_A + n_B - 2),$$

les quantiles sont donc ceux de la loi $\mathcal{T}(n_A + n_B - 2)$:

$$P(t_1 \leq T_H \leq t_2) = 1 - \alpha$$

avec $t_1 = -t_2$ et l'intervalle de confiance pour $m_A - m_B$ au niveau de confiance $1 - \alpha$ est :

$$I = \left[(\bar{X}_{n_A} - \bar{Y}_{n_B}) - t_2 \times \sqrt{\mathcal{S}^2} \sqrt{\frac{1}{n_A} + \frac{1}{n_B}} ; (\bar{X}_{n_A} - \bar{Y}_{n_B}) + t_2 \times \sqrt{\mathcal{S}^2} \sqrt{\frac{1}{n_A} + \frac{1}{n_B}} \right].$$

✱ **Intervalle de confiance pour la différence des espérances de deux variables appariées.**

Soit (X, Y) un couple de variables quantitatives appariées et soit $\Delta = X - Y$ leur différence. On suppose $\Delta \sim \mathcal{N}(m ; \sigma^2)$. Le paramètre m est l'espérance de Δ , donc la différence des moyennes théoriques de X et de Y :

$$E(\Delta) = E(X - Y) = E(X) - E(Y).$$

Les données étant appariées, la variance σ^2 est inconnue. À partir de l'échantillon $\Delta_1 = X_1 - Y_1, \dots, \Delta_n = X_n - Y_n$ on construit un intervalle de confiance de niveau $1 - \alpha$ pour m et on obtient :

$$I = \left[\bar{\Delta} - \frac{t \sqrt{S_n^2}}{\sqrt{n}} ; \bar{\Delta} + \frac{t \sqrt{S_n^2}}{\sqrt{n}} \right] \quad \text{avec} \quad S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (\Delta_i - \bar{\Delta})^2$$

où t est le quantile d'ordre $1 - \frac{\alpha}{2}$ de la loi de Student à $n - 1$ degrés de liberté.

Quel est le rapport avec les tests d'hypothèses ?

Les intervalles de confiance bilatéraux décrits dans ce cours offrent une nouvelle manière de réaliser des tests bilatéraux. Prenons l'exemple de données appariées

$$\Delta = X - Y$$

pour lesquelles on s'interroge sur la différence des moyennes théoriques : on suppose

$$\Delta \sim \mathcal{N}(m ; \sigma^2)$$

(rappelons que dans le cas de données appariées, la variance σ^2 est toujours inconnue) et on se demande si $m = 0$ ou pas. On peut répondre à cette question au risque 5%

- soit en réalisant un test de l'hypothèse $H_0 : m = 0$ contre $H_1 : m \neq 0$,
- soit en regardant si 0 est dans l'intervalle de confiance de niveau de confiance 95% pour la différence des moyennes théoriques :

$$I = \left[\bar{\Delta} - \frac{t\sqrt{S_n^2}}{\sqrt{n}} ; \bar{\Delta} + \frac{t\sqrt{S_n^2}}{\sqrt{n}} \right] \quad \text{avec} \quad S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (\Delta_i - \bar{\Delta})^2.$$

Si $0 \in I_{obs}$ alors le test de niveau 5% de $H_0 : m = 0$ contre $H_1 : m \neq 0$ ne rejettera pas H_0 ; si par contre $0 \notin I_{obs}$ alors le test de niveau 5% de $H_0 : m = 0$ contre $H_1 : m \neq 0$ rejettera H_0 .

Notons que si $0 \notin I_{obs}$, le test de $H_0 : m = 0$ contre $H_1 : m \neq 0$ rejette H_0 par la droite et conclut $m > 0$ si 0 tombe à gauche de l'intervalle de confiance, et que le test de $H_0 : m = 0$ contre $H_1 : m \neq 0$ rejette H_0 par la gauche et conclut $m < 0$ si 0 tombe à droite de l'intervalle de confiance.

Il existe aussi des intervalles de confiance unilatéraux à gauche et des intervalles de confiance unilatéraux à droite. Ces intervalles unilatéraux offrent une nouvelle manière de réaliser des tests unilatéraux.